

在新窗口打开

MemGPT (Letta): 架构演进与核心特性

从自主记忆管理到后台异步学习

演讲者: [您的名字]

日期: 2025年7月25日

MemGPT v1 - 核心理念与架构

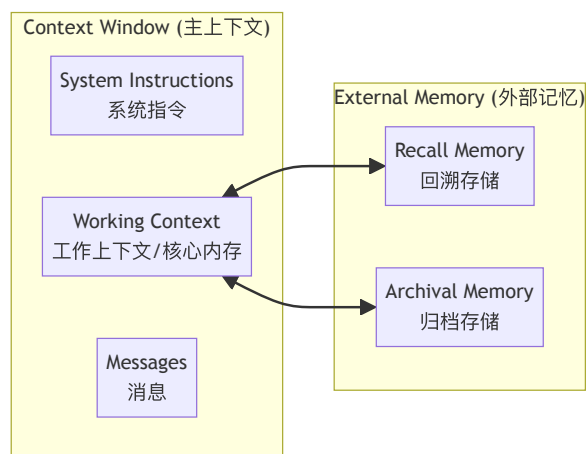
核心问题: 解决LLM的有限上下文和长期记忆缺失问题。

核心理念: 赋予Agent像操作系统(OS)一样的分层记忆管理能力，通过**函数调用 (Function Calling)** 实现自主管理。

关键组件:

- **Context Window:** LLM的工作台

- **Recall Memory:** 完整的对话历史



- **Archival
Memory:** 经
提炼的、基于向
量检索的知识库

MemGPT v1 - 核心工具集

一个强大的自主记忆管理工具箱

工具分类:

核心内存编辑: `core_memory_append`, `core_memory_replace`

长期记忆检索:

- ``conversation_search`` (搜索回溯存储)

- ``archival_memory_insert``, ``archival_memory_search`` (写入和搜索归档存储)

对外通信: `send_message`

关键机制

当上下文窗口溢出时，通过**递归摘要**压缩对话历史，确保记忆不丢失。


演进之路 - MemGPT v2 (Letta) 的架构革新

三大核心升级:

后台异步处理: 引入 Sleep-time Agent (睡眠代理)。

增强数据交互: 新增基于文件的工具 (edit_file, search_file)。

简化记忆检索: 统一的 recall 工具，整合了回溯与归档记忆的搜索。



深度解析 (1) - 核心创新： Sleep-time Agent


让思考发生在“幕后”：异步状态管理

工作机制:

本质是一个**多代理组 (Multi-agent group)**，包含主代理和睡眠代理。

睡眠代理在**后台异步运行**，不影响主代理与用户的实时交互。

主代理每隔 N 步，将新的对话历史或数据源信息“喂”给睡眠代理进行学习和提炼。



深度解析 (2) - Sleep-time Agent 的超能力


从原始信息到结构化知识的提炼

场景一：从对话中学习



将杂乱的对话内容，自动总结、提炼成结构化的用户偏好，并更新主代理的**内存块**。

场景二：从外部文档中学习



能够异步阅读 PDF 等**数据源**，生成核心内容摘要，并更新主代理的**内存块**。

深度解析 (3) - 核心机制: Heartbeat (心跳)

赋予 Agent 自主性与时间感知

主要作用:

触发后台记忆整理: 这是心跳的核心用途，定期唤醒睡眠代理 (Sleep-time Agent) 来学习和巩固记忆。

实现主动式行为: Agent不再仅仅被动响应，可以执行定时任务，如定时汇报、发送提醒等。

维持长周期任务: 对于复杂任务，心跳可以用来定期检查进度和维持状态。



总结 - MemGPT v2 (Letta) 的核心优势

效率 (Efficiency)

将耗时的记忆整理工作移至后台，主代理**响应更迅速**。

深度 (Depth)

能够处理和学习外部文档等**更复杂、更庞大的数据源**。

智能 (Intelligence)

不仅仅是存储信息，更是主动地将信息**提炼为结构化的“知识”**。

可扩展性 (Extensibility)

统一的接口和模块化设计，使其**更容易集成和扩展**。

Q & A

谢谢观看 & 问答环节

